Faculdade de
Computação e Informática

Pipeline de Inteligência Artificial para Análise de Comentários do YouTube: Classificação de Sentimentos e Extração de Padrões

Daniel Zou[1],Danilo Ye[1,2],Igor Shirata[1,3]

[1]Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

{10418211,10417890,10418106}@mackenzie.br

Resumo. *O crescimento das redes sociais, especialmente do YouTube, tem gerado um grande volume de dados em forma de comentários, que refletem opiniões, experiências e percepções dos usuários sobre produtos e conteúdos. Nesse contexto, surge a motivação de utilizar técnicas de Inteligência Artificial para analisar esses dados de forma automatizada, já que a análise manual se torna inviável. O objetivo deste projeto é desenvolver um sistema capaz de coletar e analisar comentários de vídeos do YouTube, aplicando técnicas de Processamento de Linguagem Natural (NLP) para classificar sentimentos e identificar padrões relevantes. A justificativa está na importância de compreender o comportamento dos usuários e apoiar a tomada de decisão em contextos de negócio. A metodologia envolve a coleta de dados por meio da YouTube Data API, seguida de etapas de pré-processamento, análise exploratória e aplicação de modelos de classificação de sentimento. Como resultados esperados, pretende-se automatizar a análise de comentários, identificar tendências e fornecer insights úteis sobre a percepção dos usuários.*

Palavras-chave: *Inteligência Artificial; NLP; análise de sentimento; YouTube; mineração de dados.*

Abstract. *The growth of social media platforms, especially YouTube, has generated a large volume of data in the form of user comments, reflecting opinions, experiences, and perceptions about products and content. In this context, the motivation arises to apply Artificial Intelligence techniques to automatically analyze such data, since manual analysis becomes impractical. The objective of this project is to develop a system capable of collecting and analyzing YouTube comments, applying Natural Language Processing (NLP) techniques to classify sentiments and identify relevant patterns. The justification lies in the importance of understanding user behavior and supporting decision-making processes in business contexts. The methodology includes data collection through the YouTube Data API, followed by preprocessing, exploratory data analysis, and sentiment classification models. As expected results, the project aims to automate comment analysis, identify trends, and provide useful insights regarding user perception.*

Keywords: *Artificial Intelligence; NLP; sentiment analysis; YouTube; data mining.*

1. Introdução

Nos últimos anos, o crescimento das redes sociais transformou a forma como os usuários interagem com conteúdos e produtos, tornando plataformas como o YouTube uma importante fonte de informação e opinião. Por meio dos comentários, os usuários expressam percepções, experiências e avaliações, gerando um grande volume de dados não estruturados.

Esse cenário está diretamente relacionado ao avanço da Inteligência Artificial, que tem possibilitado a análise automatizada de grandes volumes de dados, especialmente em ambientes digitais (RUSSELL; NORVIG, 2021). No entanto, apesar do potencial desses dados, sua análise manual torna-se inviável devido à quantidade e à diversidade das informações.

Nesse contexto, técnicas de Processamento de Linguagem Natural (NLP) surgem como uma alternativa eficiente para extrair conhecimento relevante a partir de textos. Segundo Araújo Júnior e Tarapanoff (2006), a mineração de textos permite identificar padrões e tendências em grandes volumes de dados, sendo amplamente utilizada em sistemas de informação.

Entretanto, ainda existe uma lacuna na aplicação prática dessas técnicas em dados reais provenientes de plataformas digitais, principalmente em língua portuguesa. Além disso, abordagens mais recentes têm buscado integrar sistemas automatizados baseados em múltiplos agentes, permitindo maior eficiência e escalabilidade na análise de dados em larga escala. Estudos recentes mostram que, embora existam avanços na área, ainda há limitações na integração de diferentes etapas de análise em um único sistema (DASHTIPOUR et al., 2021).

Diante disso, o problema de pesquisa deste trabalho consiste em como analisar automaticamente comentários do YouTube, de forma eficiente, para identificar sentimentos e padrões de comportamento dos usuários.

O objetivo geral deste projeto é desenvolver um sistema capaz de coletar e analisar comentários do YouTube, aplicando técnicas de Inteligência Artificial para classificação de sentimentos.

Como objetivos específicos, destacam-se: (i) coletar dados utilizando a YouTube Data API; (ii) realizar o pré-processamento dos textos; (iii) aplicar técnicas de NLP para análise de comentários; e (iv) classificar os dados em categorias de sentimento.

A relevância deste trabalho está na possibilidade de auxiliar empresas e criadores de conteúdo a compreender melhor o comportamento dos usuários, contribuindo para a tomada de decisão e melhoria de estratégias digitais. Além disso, o projeto contribui academicamente ao aplicar conceitos estudados na disciplina em um problema real.

Por fim, este artigo está organizado da seguinte forma: a Seção 2 apresenta o referencial teórico, a Seção 3 descreve a metodologia adotada, a Seção 4 apresenta os resultados esperados, e a Seção 5 traz as considerações finais.

2. Descrição do Problema

Atualmente, plataformas digitais como o YouTube geram um grande volume de dados em forma de comentários, que refletem opiniões, experiências e percepções dos usuários. No entanto, a análise manual desses dados torna-se inviável devido à quantidade e à velocidade com que são gerados.

Além disso, a natureza não estruturada desses dados dificulta a identificação de padrões relevantes, como sentimentos, tendências e comportamentos dos usuários. Essa limitação impacta diretamente a capacidade de empresas e criadores de conteúdo de compreenderem a percepção do público.

Outro desafio está na integração das diferentes etapas de análise, como coleta, processamento e interpretação dos dados, que muitas vezes são realizadas de forma isolada. Isso reduz a eficiência das análises e dificulta a obtenção de resultados consistentes.

Dessa forma, o problema central deste trabalho consiste em como desenvolver uma abordagem automatizada capaz de coletar, processar e analisar comentários do YouTube, utilizando técnicas de Inteligência Artificial, a fim de extrair informações relevantes de forma eficiente e escalável.

3. Referencial Teórico

O avanço das tecnologias digitais e o crescimento das redes sociais têm impulsionado o uso de técnicas de Inteligência Artificial para análise de grandes volumes de dados. Nesse contexto, plataformas como o YouTube passaram a gerar uma quantidade significativa de informações em formato textual, especialmente por meio de comentários de usuários.

A Inteligência Artificial pode ser entendida como um conjunto de métodos capazes de simular comportamentos inteligentes, como aprendizado, raciocínio e tomada de decisão (RUSSELL; NORVIG, 2021). Dentro dessa área, o aprendizado de máquina (Machine Learning) tem como objetivo identificar padrões a partir de dados, permitindo a automação de processos de análise.

No contexto de dados textuais, a mineração de textos se destaca como uma técnica fundamental para extrair informações relevantes. Segundo Araújo Júnior e Tarapanoff (2006), a mineração de textos possibilita identificar padrões, tendências e relações em grandes volumes de dados não estruturados, sendo amplamente utilizada em sistemas de informação.

Além disso, o Processamento de Linguagem Natural (NLP) permite que sistemas computacionais compreendam e analisem a linguagem humana. Com o avanço de modelos baseados em redes neurais, como o BERT (DEVLIN et al., 2019), tornou-se possível realizar tarefas mais complexas, como classificação de textos e análise de sentimento com maior precisão.

A análise de sentimento é uma das aplicações mais relevantes do NLP no contexto de redes sociais. Essa técnica permite classificar opiniões em categorias como positivas, negativas ou neutras, sendo amplamente utilizada para compreender a percepção dos usuários. De acordo com Kavitha et al. (2020), a análise de comentários no YouTube pode contribuir para a identificação de padrões de comportamento e preferências dos consumidores.

Além das abordagens tradicionais, estudos recentes têm explorado arquiteturas baseadas em sistemas multi-agent, nos quais diferentes componentes atuam de forma colaborativa na execução de tarefas específicas. Esse tipo de abordagem permite maior modularidade, escalabilidade e automação no processamento de dados complexos.

Por fim, estudos indicam que a integração de diferentes técnicas de análise, como mineração de dados e modelos de NLP, permite obter resultados mais completos e confiáveis, especialmente em ambientes digitais com grande volume de informações (DASHTIPOUR et al., 2021).

Dessa forma, observa-se que a aplicação dessas técnicas no contexto de análise de comentários do YouTube representa uma abordagem relevante tanto do ponto de vista acadêmico quanto prático, contribuindo para a geração de conhecimento e apoio à tomada de decisão.

4. Metodologia

A presente pesquisa caracteriza-se como aplicada, empírico-computacional e de abordagem quantitativa, uma vez que utiliza dados reais provenientes de uma plataforma digital para análise por meio de técnicas de Inteligência Artificial, conforme definido por Inteligência Artificial (RUSSELL; NORVIG, 2021).

O método adotado baseia-se na construção de um pipeline automatizado para coleta, processamento e análise de dados do YouTube. Essa abordagem permite tratar grandes volumes de informações de forma estruturada, garantindo maior eficiência e reprodutibilidade dos resultados, conforme discutido por Araújo Júnior e Tarapanoff (2006) na aplicação de técnicas de mineração de dados textuais.

A coleta de dados foi realizada por meio da YouTube Data API, que possibilita o acesso a informações públicas como vídeos, comentários e métricas de engajamento (GOOGLE DEVELOPERS, 2025). Os dados coletados foram armazenados inicialmente em formato estruturado para facilitar a análise.

Na etapa de processamento, foi adotada uma abordagem modular baseada em múltiplos agentes (multi-agent), na qual diferentes componentes do sistema são responsáveis por tarefas específicas, como filtragem de dados, processamento textual e análise de sentimentos. Essa estrutura contribui para a organização do pipeline e possibilita maior escalabilidade do sistema.

Após a coleta, os dados passaram por um processo de pré-processamento, incluindo limpeza de texto, remoção de duplicidades e padronização das informações.

Em seguida, foram aplicadas técnicas de Processamento de Linguagem Natural (NLP) para análise dos comentários.

Segundo BERT (DEVLIN et al., 2019), modelos baseados em transformers apresentam melhor desempenho em tarefas de classificação de texto, sendo amplamente utilizados em aplicações modernas de NLP. Esses modelos são disponibilizados por bibliotecas como a Hugging Face Transformers (HUGGING FACE, 2025), que facilitam sua implementação prática. Além disso, esses modelos são suportados por frameworks de deep learning como o PyTorch (PASZKE et al., 2019), que permitem o treinamento e execução eficiente dos algoritmos.

Além disso, os dados processados foram armazenados em um banco de dados NoSQL (MongoDB), permitindo maior flexibilidade no armazenamento e facilitando consultas futuras. Essa abordagem possibilita a organização dos dados em uma estrutura semelhante a um data lake, favorecendo a escalabilidade do sistema.

Também foi realizada uma análise exploratória dos dados (EDA), utilizando estatísticas descritivas e visualizações gráficas, com o objetivo de compreender melhor a distribuição dos dados e identificar padrões iniciais.

Por fim, os resultados foram analisados com base na distribuição dos sentimentos e na frequência de termos relevantes, permitindo identificar tendências e comportamentos dos usuários, conforme abordagens recentes em análise de dados em redes sociais (DASHTIPOUR et al., 2021).

5. Resultados Esperados

Espera-se que o sistema desenvolvido seja capaz de analisar automaticamente comentários do YouTube, classificando-os de acordo com o sentimento expresso, em categorias como positivo, negativo e neutro.

Além disso, espera-se identificar padrões de comportamento dos usuários, por meio da frequência de termos e da distribuição dos sentimentos, possibilitando uma melhor compreensão das opiniões presentes nos dados analisados.

Com a utilização de técnicas de Processamento de Linguagem Natural (NLP), espera-se obter resultados consistentes na classificação de textos, permitindo a extração de informações relevantes a partir de dados não estruturados.

A análise exploratória dos dados (EDA) também deverá contribuir para a visualização dos resultados, por meio de gráficos e estatísticas descritivas, facilitando a interpretação das informações.

Por fim, espera-se que a solução proposta possa ser utilizada como apoio na tomada de decisão, tanto em contextos acadêmicos quanto em aplicações práticas, como análise de percepção de produtos e conteúdos digitais.

6. Aspectos Éticos

O presente estudo utiliza dados públicos disponibilizados no YouTube, acessados por meio da API oficial, sem qualquer interação direta com participantes humanos. Dessa forma, enquadra-se nas disposições da Resolução CNS nº 510/2016 (BRASIL, 2016), estando dispensado de submissão ao Comitê de Ética em Pesquisa.

Os dados coletados, incluindo comentários, metadados e informações de vídeos, foram utilizados exclusivamente para fins acadêmicos, respeitando as políticas de uso da plataforma e a privacidade dos usuários.

Além disso, o projeto foi desenvolvido em ambiente computacional controlado, garantindo a integridade dos dados e a rastreabilidade dos processos de coleta e análise.

Para assegurar a reprodutibilidade do estudo, os scripts utilizados, bem como os arquivos de dados, foram organizados em repositório Git, permitindo a replicação dos experimentos e a verificação dos resultados, conforme boas práticas de pesquisa científica.

7. Dataset e Análise Exploratória

Os dados utilizados neste projeto foram coletados por meio da YouTube Data API, incluindo comentários de vídeos, informações de canais e métricas de engajamento, como número de visualizações, curtidas e quantidade de comentários (GOOGLE DEVELOPERS, 2025).

O dataset é composto por dados textuais não estruturados, contendo principalmente o conteúdo dos comentários, além de informações complementares, como identificação do vídeo, data de publicação e indicadores de interação. Esses dados foram armazenados em formato CSV, facilitando sua manipulação e análise em ambiente computacional.

Antes da análise, foi realizada uma etapa de preparação dos dados, que incluiu a remoção de registros duplicados, tratamento de valores ausentes e padronização dos textos. Também foram aplicados procedimentos de limpeza, como a remoção de caracteres especiais e normalização das palavras, com o objetivo de melhorar a qualidade dos dados para as etapas seguintes.

Em seguida, foi conduzida uma análise exploratória dos dados (EDA), com o objetivo de compreender a distribuição das informações e identificar padrões iniciais. Foram utilizadas estatísticas descritivas e visualizações gráficas para apoiar a interpretação dos dados.

A Figura 1 apresenta a distribuição do número de visualizações dos vídeos analisados. Observa-se que poucos vídeos concentram a maior parte das visualizações, caracterizando uma distribuição desigual, o que é comum em plataformas digitais, apresenta-se baixa variação na polaridade dos comentários, possivelmente devido ao tamanho reduzido do dataset utilizado nesta etapa.

Figura 1 - Distribuição de visualização dos videos

A Figura 2 ilustra a distribuição de curtidas nos comentários. Verifica-se que a maioria dos comentários apresenta baixo número de curtidas, indicando que o engajamento individual tende a ser reduzido, nota-se a predominância de um único idioma nos comentários, o que pode estar relacionado ao tipo de conteúdo analisado.

Figura 2 - Distribuição de curtidas nos comentários

A Figura 3 apresenta a distribuição dos sentimentos dos comentários. Observa-se baixa variação na polaridade dos dados, possivelmente devido ao tamanho reduzido do dataset utilizado nesta etapa, o que limita a diversidade das classificações, a baixa diversidade de tópicos pode estar associada à quantidade limitada de dados, o que reduz a capacidade de segmentação temática.

Figura 3 - Distribuição de sentimentos

A Figura 4 apresenta a relação entre o número de visualizações e a quantidade de comentários. Observa-se uma tendência positiva, indicando que vídeos mais visualizados tendem a gerar maior número de interações.

Figura 4 - Relação entre visualização e comentários

De forma geral, a análise exploratória permitiu compreender melhor o comportamento dos dados, identificar padrões iniciais e reconhecer limitações do dataset, como a baixa variabilidade em algumas dimensões, essa etapa foi fundamental para orientar as próximas fases do projeto, especialmente na aplicação das técnicas de Processamento de Linguagem Natural (NLP).

Por fim, a análise foi realizada em ambiente Python, utilizando bibliotecas como Pandas, Matplotlib e Seaborn, sendo os códigos disponibilizados em repositório GitHub para fins de reprodutibilidade.

8. Conclusão

Este trabalho teve como objetivo desenvolver uma solução baseada em Inteligência Artificial para análise automática de comentários do YouTube, com foco na identificação de sentimentos e padrões de comportamento dos usuários.

Ao longo do projeto, foram aplicadas técnicas de coleta de dados por meio da YouTube Data API, pré-processamento de dados e métodos de Processamento de Linguagem Natural (NLP), possibilitando a estruturação de um pipeline automatizado para análise de dados textuais.

Os resultados esperados indicam que a abordagem proposta pode contribuir para a classificação eficiente de comentários e para a identificação de tendências relevantes, auxiliando na compreensão da percepção dos usuários em ambientes digitais.

Como principal contribuição, destaca-se a integração de diferentes etapas de análise em um único fluxo automatizado, incluindo a utilização de uma arquitetura baseada em múltiplos agentes e o armazenamento dos dados em banco NoSQL (MongoDB), o que permite maior escalabilidade e organização do sistema.

Como limitação, ressalta-se que o projeto ainda se encontra em fase inicial, sendo necessário ampliar a base de dados e validar os resultados com experimentos mais robustos.

Como trabalhos futuros, sugere-se a melhoria dos modelos de classificação, a ampliação da análise para diferentes tipos de conteúdo e a integração com ferramentas de visualização de dados, como dashboards interativos.

8. Referências bibliográficas

ARAÚJO JÚNIOR, R. H.; TARAPANOFF, K. Precisão no processo de busca e recuperação da informação: uso da mineração de textos. *Ciência da Informação*, v. 35, n. 3, p. 236–247, 2006.

DASHTIPOUR, K.; GOGATE, M.; CAMBRIA, E.; HUSSAIN, A. A novel context-aware multimodal framework for Persian sentiment analysis. Neurocomputing, v. 457, p. 377–388, 2021. DOI: 10.1016/j.neucom.2021.02.020.

DEVLIN, J. et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT 2019), p. 4171–4186, Minneapolis, 2019. DOI: 10.18653/v1/N19-1423.

GOOGLE DEVELOPERS. YouTube Data API v3. Disponível em: https://developers.google.com/youtube/v3. Acesso em: 10 mar. 2026.

HUGGING FACE. Transformers: State-of-the-Art Natural Language Processing. Disponível em: https://huggingface.co/docs/transformers. Acesso em: 20 mar. 2026.

KAVITHA, K. M. et al. Analysis and classification of user comments on YouTube videos. Procedia Computer Science, v. 177, p. 593–598, 2020. DOI: 10.1016/j.procs.2020.10.084.

PASZKE, A. et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library. Advances in Neural Information Processing Systems (NeurIPS), v. 32, 2019.

RADFORD, A. et al. Whisper: Robust speech recognition via large-scale weak supervision. 2023.

REIMERS, N.; GUREVYCH, I. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP), p. 3982–3992, 2019. DOI: 10.18653/v1/D19-1410.

RUSSELL, S.; NORVIG, P. *Inteligência Artificial*. 4. ed. Rio de Janeiro: LTC, 2021.